



AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM - AI Conquer 2026

So sánh mô hình học máy dự đoán kết cục bệnh nhân gan: suy diễn thống kê, calibration và khả năng tái lập

Hepatic Risk Outcome Prediction

Trương Trung Tín, Lê Đức Tùng Dương, Đỗ Hồng Nhất, Đinh Văn Anh Khôi,
Nguyễn Thị Cẩm Vân



Tóm tắt nghiên cứu

Dự đoán xác suất kết cục của bệnh nhân gan là một bài toán dữ liệu bảng thuộc Healthcare AI, trong đó chất lượng xác suất quan trọng không kém độ chính xác phân loại. Bài toán gặp hai thách thức chính: nhãn mất cân bằng nghiêm trọng, với lớp ghép gan CL chỉ chiếm khoảng 2.6%, và nhiều đặc trưng lâm sàng, xét nghiệm có tỷ lệ thiếu cao. Việc chỉ xếp hạng mô hình theo điểm trung bình chưa cho biết chênh lệch có ổn định qua các fold hay xác suất có được calibration tốt hay không. Nghiên cứu xây dựng một quy trình có thể tái lập để so sánh KNN, Logistic Regression, Decision Tree, Naive Bayes, Random Forest và XGBoost trên 9.600 quan sát có nhãn. Sau tiền xử lý, sáu mô hình được đánh giá trên cùng năm fold phân tầng bằng log loss, accuracy và macro-F1. Chênh lệch log loss được phân tích bằng kiểm định ghép cặp và hiệu chỉnh Bonferroni; mô hình tốt nhất tiếp tục được đánh giá calibration trên dự đoán out-of-fold. XGBoost đạt kết quả tốt nhất với log loss 0.382 ± 0.007 , accuracy 0.850 ± 0.006 và macro-F1 0.640 ± 0.032 . Sau hiệu chỉnh, XGBoost tốt hơn Random Forest, Decision Tree, KNN và Naive Bayes; với Logistic Regression, bằng chứng chưa đủ theo exact Wilcoxon. XGBoost đạt top-label ECE 0.0117 và multiclass Brier score 0.2162. Đóng góp chính của nghiên cứu là protocol dùng chung fold, kết hợp đánh giá hiệu năng, suy diễn thống kê, calibration và ablation, cùng một cơ chế provenance trong đó cổng tái tạo phải đạt trước khi phân tích được phép chạy. Cổng này tái tạo kết quả với sai lệch metric tối đa 5.55×10^{-17} , đồng thời cho thấy nếu không pin môi trường thì riêng phiên bản thư viện đã gây sai lệch cùng bậc độ lớn với hiệu ứng cần đo.

Mục lục

I.	Giới thiệu	1
II.	Nghiên cứu liên quan	2
2.1	Dự đoán tiên lượng bệnh gan	2
2.2	Các mô hình học máy truyền thống	3
2.3	Ensemble cây và mô hình hiện đại cho dữ liệu bảng	3
2.4	Đánh giá xác suất và so sánh thống kê	3
2.5	Khoảng trống và định vị nghiên cứu	4
III.	Bài toán nghiên cứu	4
3.1	Định nghĩa input và output	4
3.2	Mục tiêu tối ưu và tiêu chí đánh giá	4
3.3	Câu hỏi và giả thuyết nghiên cứu	5
IV.	Phương pháp nghiên cứu	5
4.1	Pipeline dữ liệu	6
4.2	Thiết kế validation dùng chung	7
4.3	Các mô hình và quy tắc chọn cấu hình	7
4.4	Phân tích thống kê và calibration	7
V.	Dữ liệu và thiết kế thí nghiệm	8
5.1	Dataset và chia dữ liệu	8
5.2	Thiết lập huấn luyện và đánh giá	9
VI.	Kết quả thí nghiệm	9
6.1	Suy diễn thống kê	11
6.2	Calibration	11
VII.	Ablation Study và phân tích bổ sung	12
7.1	Ảnh hưởng của scaling	12
7.2	Cây đơn và ensemble	13
VIII.	Thảo luận	14
8.1	Trả lời các câu hỏi nghiên cứu	14

8.2	Đối chiếu với nghiên cứu trước	14
IX.	Phân tích lỗi và hạn chế	15
9.1	Hai chế độ lỗi	15
9.2	Hạn chế nghiên cứu	15
X.	Tái lập kết quả	16
XI.	Kết luận và hướng phát triển	17
XII.	Tài liệu tham khảo	18
	Phụ lục	18
A	Thông tin bổ sung	18
B	Cấu hình thí nghiệm đầy đủ	19
C	Nguồn artifact	19
D	Phân công xác nhận nội dung	20

I. Giới thiệu

Dự đoán kết cục của bệnh nhân mắc bệnh gan là một bài toán dữ liệu bảng thuộc lĩnh vực Healthcare AI. Thông tin sẵn có cho mỗi bệnh nhân không chỉ bao gồm tuổi và giới tính mà còn có thời gian theo dõi, chỉ định điều trị, giai đoạn lâm sàng, các dấu hiệu như cổ trướng, gan to, phù và sao mạch, cùng nhiều chỉ số xét nghiệm. Việc khai thác đồng thời những nguồn thông tin này có thể hỗ trợ mô hình nhận diện các mẫu liên quan đến diễn tiến bệnh. Tuy nhiên, kết quả của nghiên cứu này chỉ là đánh giá phương pháp học máy trên dữ liệu cuộc thi, không phải công cụ chẩn đoán hay khuyến nghị điều trị trong thực hành lâm sàng.

Nhiệm vụ của AIO 2026-1 Hepatic Risk Outcome Prediction yêu cầu mô hình ước lượng xác suất cho ba kết cục: bệnh nhân còn sống hoặc bị kiểm duyệt theo dõi (C), bệnh nhân được ghép gan và bị kiểm duyệt (CL), hoặc tử vong (D). Đây không đơn thuần là bài toán chọn một nhãn. Đầu ra phải là một phân phối xác suất hợp lệ, vì hệ thống đánh giá bằng multiclass log loss. Metric này phạt một dự đoán sai theo hàm logarit của xác suất gán cho nhãn thực, nên sai với độ tự tin cao tổn kém hơn nhiều bậc so với sai nhưng vẫn thể hiện độ bất định. Do đó, nghiên cứu cần xem xét đồng thời khả năng phân loại, chất lượng xác suất và calibration.

Bộ dữ liệu đặt ra ba khó khăn chính. Thứ nhất, phân bố nhãn mất cân bằng theo tỷ lệ khoảng 26:1 giữa lớp phổ biến nhất và lớp hiếm nhất: lớp C chiếm 67.9%, lớp D chiếm 29.4%, còn lớp CL chỉ 2.6%. Một mô hình thiên về lớp phổ biến vẫn có thể đạt accuracy cao nhưng hoạt động kém trên lớp hiếm. Thứ hai, nhiều biến lâm sàng và xét nghiệm có tỷ lệ thiếu cao, cao nhất là `Edema_Status` với hơn 92%. Thứ ba, các chỉ số xét nghiệm lệch phải và chênh nhau tới bốn bậc độ lớn về miền giá trị: Albumin nằm trong khoảng từ 1.94 đến 4.67, trong khi Alkaline Phosphatase trải từ 8.1 đến 19053. Vì vậy tiền xử lý ảnh hưởng trực tiếp đến các mô hình nhạy với khoảng cách hoặc regularization.

Trong bối cảnh đó, chỉ so sánh điểm trung bình của nhiều mô hình là chưa đủ. Một chênh lệch quan sát được có thể xuất phát từ một cách chia train-validation cụ thể, trong khi các mô hình lại được đánh giá trên cùng bệnh nhân ở từng fold. Nghiên cứu vì vậy tập trung vào phương pháp luận so sánh: dùng cùng năm fold phân tầng, tính cùng bộ chỉ số, thực hiện kiểm định ghép cặp trên chênh lệch theo fold, báo cáo khoảng tin cậy và kiểm soát sai số do so sánh nhiều mô hình. Ngoài hiệu năng, nghiên cứu còn đánh giá calibration của mô hình tốt nhất bằng reliability diagram, expected calibration error và Brier score.

Mục tiêu tổng quát của nghiên cứu là xây dựng một quy trình có thể tái lập để so sánh sáu họ mô hình - KNN, Logistic Regression, Decision Tree, Naive Bayes, Random Forest và XGBoost - trên cùng dữ liệu và cùng protocol. Quy trình bao phủ từ phân tích dữ liệu, tiền xử lý, cố định fold, huấn luyện đến đánh giá thống kê và calibration. Qua đó, nghiên cứu hướng tới một kết luận thận trọng hơn câu hỏi “mô hình nào có điểm thấp nhất”: kết quả tốt hơn bao nhiêu, có ổn định qua fold hay không, xác suất có đáng tin cậy hay không, và toàn bộ kết quả có thể được truy vết tới artifact nguồn hay không.

Đóng góp

Nghiên cứu có năm đóng góp chính:

- **Xây dựng pipeline dữ liệu thống nhất và có thể kiểm tra.** Dữ liệu được tổ chức theo ba tầng `raw`, `interim` và `processed`; pipeline xử lý dữ liệu thiếu, bổ sung cờ `missing`,

encode biến phân loại, biến đổi $\log_{1p}$ cho biến lệch phải và lưu đồng thời phiên bản có/không scaling.

- **Thiết lập protocol so sánh công bằng cho sáu mô hình.** Năm fold phân tầng với seed 42 được tạo một lần và dùng chung cho mọi model track. Nhờ đó, điểm của các mô hình được ghép đúng theo cùng fold, tránh việc so sánh các kết quả đến từ những lần chia dữ liệu khác nhau.
- **Đánh giá thực nghiệm đa chiều.** Sáu mô hình thuộc ba track được so sánh bằng log loss, accuracy và macro-F1. Nghiên cứu bổ sung ablation về ảnh hưởng của scaling đối với KNN và Logistic Regression, đồng thời phân tích sự khác biệt giữa cây đơn không regularization, cây giới hạn độ sâu, Random Forest và XGBoost.
- **Bổ sung tầng suy diễn thống kê và calibration.** Chênh lệch log loss được phân tích bằng kiểm định ghép cặp, Shapiro-Wilk, exact Wilcoxon khi giả định chuẩn không phù hợp, khoảng tin cậy và hiệu chỉnh Bonferroni cho năm phép so sánh. Mô hình tốt nhất còn được đánh giá bằng top-label ECE, classwise ECE, Brier score và phân tích độ nhạy theo số bin.
- **Thiết lập provenance có thể kiểm chứng và công tái tạo chặn cứng.** Thay vì chỉ tuyên bố kết quả tái lập được, nghiên cứu ràng buộc điều đó bằng cơ chế thực thi. Môi trường được pin đầy đủ trong `requirements.lock.txt` (160 package); manifest chụp lại hash SHA-256 của tám tệp đầu vào cùng cấu hình booster đầy đủ của từng fold, qua đó cố định cả những siêu tham số mặc định không được khai báo tường minh trong mã. Một công tái tạo so từng metric với dung sai 10^{-5} và *chặn* phân tích calibration bằng lỗi thực thi cho tới khi cố định. Phần X. trình bày kết quả áp dụng cơ chế này.

II. Nghiên cứu liên quan

2.1 Dự đoán tiên lượng bệnh gan

Nghiên cứu tiên lượng bệnh gan có lịch sử lâu hơn các benchmark phân loại hiện đại. Dickson và cộng sự xây dựng mô hình Cox từ dữ liệu bệnh nhân xơ gan mật nguyên phát tại Mayo Clinic, sử dụng tuổi, bilirubin, albumin, thời gian prothrombin và mức độ phù để dự đoán sống còn. Mô hình được kiểm tra trên một tập bệnh nhân độc lập và có ưu điểm không yêu cầu sinh thiết gan [1]. Công trình này cho thấy các biến lâm sàng và xét nghiệm dạng bảng có thể mang tín hiệu tiên lượng hữu ích, đồng thời nhấn mạnh vai trò của đánh giá ngoài mẫu.

Một benchmark liên quan trực tiếp là Cirrhosis Patient Survival Prediction trong UCI Machine Learning Repository. Bộ dữ liệu có 418 bệnh nhân, 17 đặc trưng và ba trạng thái D, C, CL; dữ liệu bắt nguồn từ nghiên cứu Mayo Clinic giai đoạn 1974-1984 [2]. Bộ dữ liệu của cuộc thi hiện tại có cấu trúc biến và định nghĩa nhãn tương tự. Gói dữ liệu hiện có gồm 9.600 quan sát train, 2.400 quan sát validation riêng và 10.000 quan sát test. Do ban tổ chức không cung cấp trong repo một tài liệu mô tả chính thức về quy trình mở rộng dữ liệu, nghiên cứu này không giả định rằng hai bộ dữ liệu hoàn toàn giống nhau và không dùng kết quả trên UCI làm benchmark số trực tiếp.

2.2 Các mô hình học máy truyền thống

Các phương pháp truyền thống cung cấp những baseline với giả định khác nhau. Logistic Regression mô hình hóa log-odds tuyến tính, huấn luyện nhanh và tạo xác suất trực tiếp, nhưng có thể bỏ sót quan hệ phi tuyến hoặc tương tác phức tạp. KNN không giả định dạng hàm và tận dụng cấu trúc cục bộ, song nhạy với scaling, nhiễu, chiều dữ liệu và lựa chọn số láng giềng. Naive Bayes có chi phí thấp nhưng giả định độc lập có điều kiện thường không phù hợp hoàn toàn với các chỉ số xét nghiệm có tương quan. Decision Tree dễ diễn giải và học được ngưỡng phi tuyến, nhưng cây sâu có phương sai lớn và thường tạo xác suất 0 hoặc 1 ở các lá ít mẫu, điều đặc biệt bất lợi khi metric là log loss.

Bốn baseline này được giữ lại ngay cả khi ensemble cho kết quả cao hơn, vì mỗi mô hình vi phạm một giả định khác nhau và nhờ đó khoanh vùng được nguyên nhân của chênh lệch quan sát được.

2.3 Ensemble cây và mô hình hiện đại cho dữ liệu bảng

Random Forest kết hợp nhiều cây được huấn luyện trên bootstrap samples và sử dụng ngẫu nhiên đặc trưng tại mỗi nút. Breiman chỉ ra rằng sai số tổng quát phụ thuộc vào sức mạnh của từng cây và tương quan giữa chúng; việc averaging giúp mô hình ổn định hơn cây đơn và tương đối bền vững trước nhiễu [3]. Hạn chế của Random Forest là nhiều cây có thể làm tăng chi phí suy luận, còn xác suất trung bình không mặc nhiên bảo đảm calibration tối ưu.

XGBoost xây dựng cây tuần tự để sửa sai của ensemble hiện tại, kết hợp regularized objective, shrinkage, subsampling và các tối ưu cho dữ liệu thưa. Công trình gốc mô tả một hệ thống tree boosting có khả năng mở rộng, kèm thuật toán nhận biết tính thưa và cơ chế weighted quantile sketch cho việc học cây xấp xỉ [4]. Với dữ liệu bảng có quan hệ phi tuyến, tương tác và missingness, gradient-boosted trees thường là ứng viên phù hợp; tuy nhiên, hiệu năng phụ thuộc vào siêu tham số và việc dùng cùng fold để tuning và đánh giá có thể tạo selection bias.

Các kiến trúc deep learning nằm ngoài phạm vi nghiên cứu. Dữ liệu ở đây là bảng kích thước vừa, không chứa ảnh, văn bản hay tín hiệu tuần tự cần representation learning; thêm mạng sâu mà không có protocol tuning tương xứng sẽ mở rộng không gian thử nghiệm mà không phục vụ câu hỏi nghiên cứu.

2.4 Đánh giá xác suất và so sánh thống kê

Accuracy chỉ đánh giá lớp có xác suất lớn nhất và không phân biệt dự đoán đúng với độ tự tin 0.51 hay 0.99. Log loss và Brier score đánh giá toàn bộ phân phối xác suất; Brier score bắt nguồn từ nghiên cứu về kiểm chứng dự báo xác suất [5]. Reliability diagram và ECE đo khoảng cách giữa mức confidence và tần suất đúng quan sát được. Guo và cộng sự cho thấy mô hình có accuracy tốt vẫn có thể calibration kém và temperature scaling là một baseline hậu xử lý hiệu quả trong nhiều thiết lập [6]. Dù công trình đó tập trung vào mạng nơ-ron, kết luận khái quát rằng hiệu năng phân loại và calibration là hai khía cạnh khác nhau vẫn phù hợp với nghiên cứu này.

So sánh nhiều mô hình cũng làm phát sinh nguy cơ kết luận dương tính giả nếu thực hiện nhiều kiểm định mà không hiệu chỉnh. Demšar tổng hợp các phương pháp so sánh classifier và khuyến

ngiht các kiểm định phi tham số như Wilcoxon trong những thiết lập phù hợp, đồng thời nhấn mạnh vấn đề multiple comparisons [7]. Nghiên cứu kế thừa nguyên tắc kiểm định ghép cặp và kiểm soát family-wise error, nhưng chỉ có năm fold trên một dataset; vì vậy độ phân giải của kiểm định thấp và các fold không thể được xem như năm dataset độc lập.

2.5 Khoảng trống và định vị nghiên cứu

Các công trình trên xác lập rằng dữ liệu bảng lâm sàng mang tín hiệu tiên lượng, rằng ensemble cây thường mạnh trên loại dữ liệu này, và rằng chất lượng xác suất phải được đo tách khỏi accuracy. Điều còn thiếu là một so sánh trong đó cả ba nhận định đó được kiểm chứng đồng thời trên cùng một phân hoạch dữ liệu: xếp hạng sáu họ mô hình theo mean log loss không cho biết chênh lệch có nhất quán qua fold và có sống sót sau hiệu chỉnh so sánh bội hay không, cũng không cho biết xác suất của mô hình đứng đầu có đáng tin hay không.

Nghiên cứu này không đề xuất kiến trúc mới. Đóng góp nằm ở protocol: một phân hoạch dùng chung cho phép ghép cặp kết quả, kèm tăng suy diễn thống kê, phân tích calibration và cơ chế provenance mô tả ở Mục I.. Bốn khoảng trống vừa nêu được chuyển thành RQ1-RQ4 ở phần tiếp theo.

III. Bài toán nghiên cứu

3.1 Định nghĩa input và output

Bài toán là phân loại đa lớp trên dữ liệu bảng. Gọi $\mathbf{x}_i \in \mathcal{X}$ là vector đặc trưng của bệnh nhân thứ i , hình thành từ bốn nhóm thông tin: nhân khẩu học; thời gian theo dõi, điều trị và giai đoạn lâm sàng; dấu hiệu lâm sàng; và chỉ số xét nghiệm. Cột id chỉ dùng để định danh, không tham gia làm đặc trưng. Nhãn đích là $y_i \in \mathcal{Y} = \{C, CL, D\}$, tương ứng với còn sống hoặc bị kiểm duyệt theo dõi, được ghép gan và bị kiểm duyệt, và tử vong.

Mô hình $f_\theta : \mathcal{X} \rightarrow \Delta^2$ ánh xạ mỗi bệnh nhân thành một vector xác suất

$$\hat{\mathbf{p}}_i = f_\theta(\mathbf{x}_i) = (\hat{p}_{i,C}, \hat{p}_{i,CL}, \hat{p}_{i,D}),$$

trong đó $0 \leq \hat{p}_{i,k} \leq 1$ và $\hat{p}_{i,C} + \hat{p}_{i,CL} + \hat{p}_{i,D} = 1$. Thứ tự ba lớp phải được giữ cố định xuyên suốt quá trình encode nhãn, gọi `predict_proba` và tính metric; một hoán vị cột không bị phát hiện sẽ làm sai lệch toàn bộ log loss mà không gây lỗi chạy.

3.2 Mục tiêu tối ưu và tiêu chí đánh giá

Metric chính là multiclass log loss:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{k \in \{C, CL, D\}} y_{ik} \log(\hat{p}_{i,k}),$$

trong đó $y_{ik} = 1$ nếu quan sát i thuộc lớp k và bằng 0 trong các trường hợp còn lại. Log loss càng thấp càng tốt. Do logarit phân kỳ khi xác suất tiến về 0, đóng góp của một quan sát vào tổng không bị chặn trên. Đặc tính này khiến các mô hình sinh xác suất cực đoan, như cây đơn

quá sâu hoặc KNN với ít láng giềng, chịu log loss cao hơn nhiều so với mức mà accuracy của chúng gợi ý.

Accuracy được báo cáo để thể hiện tỷ lệ dự đoán đúng theo lớp có xác suất cao nhất. Macro-F1 tính F1 riêng cho từng lớp rồi lấy trung bình không trọng số, nhờ đó phản ánh tốt hơn hiệu năng trên lớp CL hiếm. Hai chỉ số này là metric bổ trợ; quyết định mô hình cuối vẫn dựa trước hết vào log loss. Với mô hình có log loss thấp nhất, nghiên cứu tiếp tục đánh giá calibration bằng ECE và Brier score để phân biệt giữa khả năng xếp đúng lớp và độ tin cậy của xác suất.

3.3 Câu hỏi và giả thuyết nghiên cứu

- **RQ1:** Trong sáu mô hình được khảo sát, mô hình nào đạt mean 5-fold log loss thấp nhất, đồng thời duy trì accuracy và macro-F1 cạnh tranh?
- **RQ2:** Chênh lệch log loss giữa mô hình đứng đầu và từng comparator có đủ bằng chứng thống kê sau khi kiểm tra giả định và hiệu chỉnh năm phép so sánh hay không?
- **RQ3:** Scaling ảnh hưởng như thế nào đến KNN và Logistic Regression, và regularization và ensemble ảnh hưởng như thế nào đến độ cực đoan của xác suất cây?
- **RQ4:** Xác suất out-of-fold của mô hình tốt nhất có calibration tốt không, và kết luận ECE có ổn định khi thay đổi số bin hay không?

Giả thuyết nghiên cứu

H1 ứng với RQ1: Trong sáu mô hình khảo sát, gradient boosting có regularization đạt mean 5-fold log loss thấp nhất mà không phải đánh đổi accuracy hay macro-F1.

H2 ứng với RQ2: Chênh lệch log loss giữa mô hình đứng đầu và từng comparator đủ lớn và đủ nhất quán qua năm fold để vượt ngưỡng ý nghĩa sau hiệu chỉnh Bonferroni.

H3 ứng với RQ3: Scaling cải thiện KNN vì khoảng cách Euclid không còn bị chi phối bởi đặc trưng có miền giá trị lớn; với cây, regularization độ sâu và ensemble hạ log loss chủ yếu bằng cách loại bỏ xác suất bằng 0 gán cho lớp đúng, chứ không bằng cách hạ thấp mức độ tự tin nói chung.


H4 ứng với RQ4: Xác suất out-of-fold của mô hình có log loss thấp nhất có sai lệch calibration nhỏ, và kết luận ECE ổn định khi thay đổi số bin.

Mỗi câu hỏi nghiên cứu gắn với đúng một giả thuyết cùng số thứ tự. H3 có hai vế vì RQ3 hỏi về hai họ mô hình khác nhau. Cả bốn giả thuyết được đánh giá hoàn toàn trên validation 5-fold nội bộ. Protocol được chốt trước khi hợp nhất bảng điểm và không được điều chỉnh hồi tố theo kết quả quan sát.

IV. Phương pháp nghiên cứu

Nghiên cứu không đề xuất kiến trúc mô hình mới; thành phần được thiết kế là **protocol so sánh**. Hình 1 mô tả pipeline nghiên cứu và chỉ rõ vị trí của thành phần đó: khối *shared 5-fold* nằm giữa tiền xử lý và huấn luyện, buộc mọi mô hình nhận đúng cùng một phân hoạch dữ liệu.

Nhờ vậy, năm điểm log loss của hai mô hình bất kỳ tạo thành các cặp ghép hợp lệ, cho phép kiểm định ghép cặp thay vì chỉ so sánh trung bình rời rạc.



Hình 1: Pipeline nghiên cứu. Khối tô đậm là thành phần phương pháp luận được khảo sát: một phân hoạch 5-fold cố định dùng chung cho toàn bộ sáu mô hình, tạo điều kiện cho suy diễn thống kê ghép cặp ở Bảng 2.

4.1 Pipeline dữ liệu

Quy trình được tổ chức theo ba tầng `raw` $\rightarrow$ `interim` $\rightarrow$ `processed`. Tầng `raw` giữ nguyên CSV do ban tổ chức cung cấp. Ở tầng `interim`, `Patient_Age_Days` được chuyển thành tuổi theo năm; `Edema_Status` bị loại do thiếu 92.01% nhưng vẫn giữ một cờ biểu thị missingness; các biến có tỷ lệ thiếu cao được bổ sung cờ thiếu tương ứng. Biến số được điền bằng median tính trên train; biến phân loại thiếu được gán nhãn `Unknown`. ID và fold ID không được đưa vào tập đặc trưng.

Ở tầng `processed`, sáu biến lệch phải gồm Bilirubin, Cholesterol, Copper, Alkaline Phosphatase, AST và Triglyceride được biến đổi `log1p`. Tỷ lệ Bilirubin/Albumin được bổ sung như một đặc trưng dẫn xuất và cũng qua `log1p`. Các biến phân loại được mã hóa bằng `OrdinalEncoder`; giá trị chưa từng thấy ở test nhận mã `-1`. Đặc trưng số được scale bằng `RobustScaler`, phù hợp hơn `StandardScaler` khi có outlier. Pipeline tạo 31 đặc trưng cuối cùng và lưu thêm một phiên bản không scale có cùng cột, cùng encoding và cùng biến đổi để thực hiện ablation.

Một giới hạn cần công khai là median, encoder và scaler hiện được fit một lần trên toàn bộ 9.600 dòng train trước khi chạy cross-validation, thay vì được fit riêng trong từng training fold. Cách làm này không dùng nhãn validation nhưng vẫn cho phép thống kê phân phối của validation đi vào tiền xử lý, tạo leakage nhẹ và có thể làm score hoặc calibration lạc quan. Báo cáo giữ nguyên artifact đã freeze và đưa vấn đề này vào phần hạn chế; phiên bản tiếp theo cần dùng `Pipeline/ColumnTransformer` bên trong từng fold.

4.2 Thiết kế validation dùng chung

Phân hoạch Stratified 5-Fold được sinh với `shuffle=True` và seed 42, sau đó lưu cố định tại `data/interim/fold_id.csv`. Mỗi fold có 1.920 mẫu; fold 0 gồm 1.305 C, 50 CL và 565 D, còn mỗi fold 1-4 gồm 1.304 C, 51 CL và 565 D. Toàn bộ 9.600 ID train là duy nhất. Mọi model track dùng cùng fold ID và huấn luyện lại mô hình từ đầu ở mỗi fold; điều này tạo các cặp điểm hợp lệ cho so sánh thống kê. Không có oversampling, class weighting hay dữ liệu test trong quá trình đánh giá.

4.3 Các mô hình và quy tắc chọn cấu hình

4.3.1 Track A: KNN và Logistic Regression

KNN được quét `n_neighbors` trong $\{3, 5, 7, 9, 11, 15, 21, 31, 41, 51\}$ trên shared 5-fold và chọn theo mean log loss; $k = 51$ là cấu hình tốt nhất. Các tham số còn lại dùng mặc định của scikit-learn: uniform weights và khoảng cách Minkowski với $p = 2$ (Euclid). Logistic Regression dùng regularization L2 mặc định, $C = 1$, solver mặc định `lbfgs`, `max_iter=1000` và seed 42. Cả hai nhận bản dữ liệu đã scale. Bản không scale chỉ dùng cho ablation và không tham gia bảng xếp hạng cuối.

4.3.2 Track B: Decision Tree và Naive Bayes

Decision Tree được quét `max_depth` trong $\{2, 3, 4, 5, 6, 8, 10, 12, 15, 20, \text{None}\}$ và chọn độ sâu 3 theo mean log loss. Mô hình dùng criterion Gini, `min_samples_leaf=1` và seed 42. Baseline thứ hai là GaussianNB với `var_smoothing=10-9` mặc định. Project không clip xác suất ở tầng metric; `sklearn.log_loss` tự bảo vệ phép log ở machine epsilon. Quyết định này giúp ablation phản ánh đúng hậu quả của xác suất 0 do cây không giới hạn độ sâu.

4.3.3 Track C: Random Forest và XGBoost

Cả hai mô hình được grid search trên số cây và độ sâu; riêng XGBoost quét thêm learning rate. Cấu hình chốt là Random Forest 600 cây độ sâu 14, và XGBoost 400 cây độ sâu 2 với learning rate 0.15 - tức một ensemble sâu, ít cây so với một ensemble nông, nhiều cây. Không gian quét đầy đủ xem Bảng 3. Nghiên cứu không dùng early stopping và không dùng class weights, để chênh lệch giữa hai mô hình phản ánh cơ chế bagging so với boosting chứ không phản ánh mức độ can thiệp vào lớp hiếm. Sau khi freeze, hai mô hình được chạy lại trên cùng năm fold để tạo bảng điểm cuối và OOF prediction.

4.4 Phân tích thống kê và calibration

XGBoost được chọn làm mô hình tham chiếu sau khi có mean log loss thấp nhất. Với mỗi comparator, năm chênh lệch ghép cặp được tính theo $d_j = \mathcal{L}_{\text{XGB},j} - \mathcal{L}_{\text{comp},j}$, trong đó $d_j < 0$ nghiêng về XGBoost. Shapiro-Wilk được dùng như cổng chọn primary test: paired t-test nếu $p \geq 0.05$, exact Wilcoxon hai phía nếu $p < 0.05$. Năm phép so sánh được hiệu chỉnh Bonferroni với family-wise $\alpha = 0.05$, nên adjusted alpha là 0.01. T-based 95% CI được báo cáo như đại lượng mô tả cho chênh lệch trung bình; kết luận chính dựa trên primary test. Với XGBoost, OOF prediction chỉ được dùng cho calibration sau khi cổng tái tạo xác nhận metric khớp score theo cả năm fold. Calibration được mô tả bằng reliability diagram, top-label ECE, macro classwise


ECE, multiclass Brier score và phân tích độ nhạy với 5, 10, 15, 20 bins.

V. Dữ liệu và thiết kế thí nghiệm

5.1 Dataset và chia dữ liệu

Gói dữ liệu gồm aio26_train.csv (9.600 dòng, 18 đặc trưng, ID và nhãn), aio26_val.csv (2.400 dòng có nhãn), aio26_test.csv (10.000 dòng không nhãn). Phân tích chính và toàn bộ bảng so sánh thống kê trong báo cáo được tạo từ 9.600 dòng train trên shared 5-fold; file val riêng không được gộp vào các điểm này. Tập test không có nhãn nên không tham gia tuning hay đánh giá ở bất kỳ bước nào của nghiên cứu.

Trong train, C có 6.521 mẫu (67.93%), D có 2.825 mẫu (29.43%) và CL có 254 mẫu (2.65%). Mỗi lượt huấn luyện dùng 7.680 mẫu và đánh giá trên 1.920 mẫu còn lại.



Hình 2: Tổng quan kích thước, phân bố nhãn và tỷ lệ thiếu trên tập train 9.600 mẫu.

Hình 2 tổng hợp ba đặc điểm chi phối thiết kế thí nghiệm: quy mô dữ liệu, mức mất cân bằng nhãn và tỷ lệ thiếu theo biến. EDA cho thấy **Edema_Status** thiếu 92.01%, Triglyceride và Cholesterol thiếu lần lượt 55.66% và 55.35%; nhiều biến điều trị, dấu hiệu và xét nghiệm thiếu khoảng 43%.

Bilirubin, Alkaline Phosphatase, Copper, Cholesterol và một số xét nghiệm khác có phân phối lệch phải, với trung bình lớn hơn trung vị và đuôi phải kéo dài. So sánh histogram mật độ của tám biến chính giữa train và test không cho thấy dịch chuyển phân phối nổi bật bằng quan sát trực quan. Tuy nhiên, notebook chưa thực hiện một kiểm định drift định lượng hoặc đặt ngưỡng phát hiện trước, nên kết quả này chỉ là chẩn đoán EDA, không phải bằng chứng rằng hai phân phối hoàn toàn giống nhau.

5.2 Thiết lập huấn luyện và đánh giá

Môi trường authoritative được ghi trong `requirements.lock.txt`: Python 3.9.18, XGBoost 2.1.4, scikit-learn 1.6.1, NumPy 1.26.4, pandas 2.3.3, SciPy 1.13.1 và Matplotlib 3.9.2. Seed thống nhất là 42. Notebook không ghi model CPU, RAM hoặc GPU, vì vậy runtime chỉ mô tả lần chạy hiện tại và không được diễn giải như benchmark phần cứng.


Mỗi mô hình được clone và fit lại từ đầu trên từng training fold. Hàm metric dùng cùng thứ tự nhãn $[0, 1, 2]$ để tránh lỗi khi lớp hiếm ít xuất hiện. Log loss là metric chọn cấu hình và xếp hạng; accuracy và macro-F1 được báo cáo bổ sung. Kết quả cuối gồm $6 \times 5 = 30$ dòng score. Runtime được đo riêng cho fit và `predict_proba`; mọi dòng đều có cờ xác nhận log loss khớp bằng score.

Quy trình tuning chọn siêu tham số bằng mean log loss trên chính shared folds rồi báo cáo hiệu năng trên cùng folds. Đây là một grid-search CV nhất quán giữa mô hình nhưng không phải nested CV; do đó kết quả có thể lạc quan. Sau khi chọn, tham số được freeze trước khi hợp nhất bảng score và chạy phân tích thống kê.

VI. Kết quả thí nghiệm

Bảng 1: Hiệu năng 5-fold (trung bình $\pm$ độ lệch chuẩn).

Mô hình	Log loss $\downarrow$	Accuracy $\uparrow$	Macro-F1 $\uparrow$
XGBoost	0.382 ± 0.007	0.850 ± 0.006	0.640 ± 0.032
Random Forest	0.406 ± 0.006	0.848 ± 0.007	0.569 ± 0.008
Logistic Regression	0.441 ± 0.009	0.833 ± 0.005	0.558 ± 0.014
Decision Tree	0.474 ± 0.011	0.830 ± 0.007	0.529 ± 0.008
KNN	0.660 ± 0.055	0.814 ± 0.009	0.515 ± 0.010
Naive Bayes	2.211 ± 0.217	0.589 ± 0.030	0.466 ± 0.019



Hình 3: Phân bố log loss của sáu mô hình trên cùng năm fold; mỗi chấm là một fold. Trục y bị ngắt ở khoảng 0.8–1.8 vì không có quan sát nào rơi vào đó.

Bảng 1 và Hình 3 trình bày hiệu năng 5-fold của sáu mô hình trên cùng bộ fold. XGBoost đứng đầu trên cả ba giá trị trung bình. So với Random Forest, log loss giảm từ 0.406 xuống 0.382 trong khi accuracy chỉ tăng khoảng 0.002; phần cải thiện rõ hơn nằm ở macro-F1, tăng từ 0.569 lên 0.640. Điều này đặc biệt đáng chú ý trong bối cảnh lớp CL hiếm, nhưng chưa đủ để kết luận chất lượng riêng của lớp CL nếu không xem thêm confusion matrix và các chỉ số theo lớp. Logistic Regression đứng thứ ba về log loss (0.441), cho thấy baseline tuyến tính vẫn cạnh tranh. KNN và Naive Bayes có log loss cao dù accuracy không giảm theo cùng tỷ lệ, minh họa lý do không nên dùng accuracy làm tiêu chí duy nhất cho bài toán dự đoán xác suất.


Hình 3 bổ sung điều mà giá trị trung bình che mất: thứ hạng này giữ nguyên ở cả năm fold, nhưng độ ổn định giữa các mô hình khác nhau rõ rệt. Bốn mô hình đầu có khoảng biến thiên hẹp (0.014–0.027 log loss giữa fold tốt nhất và tệ nhất), trong khi KNN trải 0.602–0.738 và Naive Bayes trải 1.880–2.431. Điểm số của hai mô hình sau vì thế phụ thuộc đáng kể vào việc rơi trúng fold nào, và đó là lý do phần suy diễn dùng kiểm định ghép cặp theo fold thay vì so trực tiếp hai giá trị trung bình.

Về chi phí chạy, runtime theo fold cho thấy Decision Tree và Naive Bayes fit nhanh nhất; Logistic Regression cũng nhẹ. XGBoost fit trung bình khoảng 0.64 giây/fold, nhanh hơn Random Forest khoảng 1.19 giây/fold trong môi trường ghi nhận. Thời gian suy luận KNN không ổn định, với fold đầu là ngoại lệ lớn; do đó runtime chỉ nên được xem là mô tả cho lần chạy hiện tại, không phải benchmark phần cứng tổng quát. Thứ hạng trung bình vẫn cần được đọc cùng suy diễn ghép cặp ở Bảng 2.

6.1 Suy diễn thống kê

Bảng 2: So sánh chính của XGBoost. CI là t-based 95% CI; kết luận dựa trên primary test.

Comparator	$\bar{d}$	CI 95%	Shapiro p	p chỉnh	Kết luận
Random Forest	-.0240	[-.0287,-.0192]	.4627	.00075	XGB tốt hơn
Logistic Regression	-.0586	[-.0673,-.0498]	.0142	.31250	Chưa đủ bằng chứng
Decision Tree	-.0923	[-.1035,-.0812]	.5161	.00011	XGB tốt hơn
KNN	-.2783	[-.3496,-.2071]	.3438	.00205	XGB tốt hơn
Naive Bayes	-1.8287	[-2.0919,-1.5656]	.5702	.00021	XGB tốt hơn




Hình 4: Chênh lệch log loss theo fold giữa XGBoost và từng mô hình so sánh, kèm CI 95% t-based. Điểm đặc là các so sánh đạt ngưỡng sau Bonferroni, điểm rỗng là Logistic Regression – nơi CI nằm trọn bên trái vạch 0 nhưng primary test (Wilcoxon) không kết luận được. Naive Bayes nằm ngoài thang của hình, số đầy đủ ở Bảng 2.

Bảng 2 và Hình 4 trình bày cùng năm so sánh chính; bốn trong năm đạt ngưỡng đã hiệu chỉnh. Ngoại lệ là Logistic Regression, nơi Shapiro-Wilk bác bỏ giả định chuẩn nên primary test chuyển sang exact Wilcoxon; với $n = 5$, p-value hai phía nhỏ nhất mà kiểm định này có thể trả về là .0625, đã vượt ngưỡng .01 trước khi nhìn dữ liệu. “Chưa đủ bằng chứng” vì vậy phản ánh giới hạn độ phân giải của thiết kế, không phải bằng chứng về sự tương đương. Khoảng tin cậy t-based của cả năm chênh lệch đều nằm dưới 0, nhưng ở riêng cặp này chúng chỉ là phân tích độ nhạy. Mọi kết luận còn bị giới hạn bởi việc các tập huấn luyện giữa năm fold chồng lấp nhau, nên năm chênh lệch không phải năm quan sát độc lập.

6.2 Calibration

XGBoost có top-label ECE 0.0117, macro classwise ECE 0.0085 và multiclass Brier score 0.2162 với 10 bins. ECE dao động 0.0117-0.0144 khi dùng 5-20 bins.



Hình 5: Reliability diagram của XGBoost trên dự đoán out-of-fold có provenance hợp lệ.

Hình 5 cho thấy đường reliability bám sát đường chéo lý tưởng ở vùng confidence cao. Trong bảy top-label bins có dữ liệu, accuracy quan sát luôn thấp hơn confidence, tức XGBoost overconfident theo một hướng nhất quán chứ không dao động ngẫu nhiên quanh đường chéo. Biên độ lệch nhỏ và tập trung ở vùng thừa dữ liệu: bin $[0.9, 1.0)$ chứa 5.416 mẫu, tương đương 56.4% quan sát, nhưng chỉ lệch 0.00006; ngược lại mọi khoảng lệch vượt 0.03 đều nằm ở bin có confidence dưới 0.7, trong đó bin $[0.3, 0.4)$ chỉ có 13 mẫu. Ba bin dưới 0.3 trống là hệ quả cấu trúc của bài toán ba lớp, vì xác suất lớn nhất luôn ít nhất bằng $1/3$.


Classwise ECE lần lượt là 0.0119 cho C, 0.0038 cho CL và 0.0097 cho D. Giá trị thấp nhất thuộc về CL không được diễn giải là calibration tốt nhất. Lớp này chỉ có 254 mẫu, và 94.5% toàn bộ quan sát rơi vào bin xác suất CL $[0, 0.1)$; ECE khi đó chủ yếu đo mức khớp giữa xác suất gần 0 và tần suất xuất hiện gần 0, một phép đo gần như luôn đạt với lớp hiếm bất kể mô hình có phân biệt được CL hay không. Phân tích chỉ đo calibration OOF; không fit Platt, isotonic hay temperature scaling, và không đưa ra kết luận về calibration trên test ẩn.

VII. Ablation Study và phân tích bổ sung

7.1 Ảnh hưởng của scaling

Hình 6 đối chiếu hai biến thể dữ liệu có và không scaling trên cùng năm fold. Với KNN $k = 51$, scaling giảm mean log loss từ 0.752 xuống 0.660, đồng thời tăng accuracy từ 0.780 lên 0.814 và macro-F1 từ 0.477 lên 0.515. Logistic Regression hưởng lợi ít hơn: mean log loss giảm từ 0.483 xuống 0.441. Chênh lệch giữa hai mô hình phù hợp với cơ chế của chúng. Khoảng cách Euclid của KNN cộng trực tiếp bình phương sai lệch trên mọi chiều, nên một biến trải bốn bậc độ lớn có thể chi phối toàn bộ phép đo; Logistic Regression chỉ chịu ảnh hưởng gián tiếp qua điều kiện số của bài toán tối ưu và qua mức phạt L2 áp lên các hệ số có thang đo khác nhau.

Số láng giềng có tác động lớn hơn scaling. KNN $k = 5$ đạt mean log loss 2.448 khi scale và 3.055 khi không scale, tức cao gấp khoảng bốn lần $k = 51$ trong cùng điều kiện. Xác suất ước lượng từ năm láng giềng chỉ nhận các bội của $1/5$, nên một quan sát bị phân loại sai sẽ nhận xác suất bằng 0 cho nhãn thực và bị log loss phạt không giới hạn.




Hình 6: Ablation ảnh hưởng của scaling đối với KNN và Logistic Regression.

7.2 Cây đơn và ensemble

Decision Tree không giới hạn độ sâu có OOF log loss 8.309: toàn bộ mẫu nhận xác suất cực đại trên 0.99 và 23.1% mẫu có xác suất gán cho lớp đúng bằng đúng không. Giới hạn `max_depth=3` giảm log loss xuống 0.474, Random Forest xuống 0.406 và XGBoost xuống 0.382.

Hình 7 cho thấy hai đại lượng này *không* biến thiên cùng chiều. Log loss giảm đơn điệu theo thứ tự trên, nhưng tỷ lệ mẫu có $p_{\max} > 0.99$ lại đi 100%, 0%, 0.6% rồi 7.7%: XGBoost là mô hình tự tin nhất trong ba mô hình đã regularize, đồng thời cũng là mô hình tốt nhất. Mức độ tự tin vì vậy không phải biến giải thích.

Biến phân biệt nằm ở xác suất nhỏ nhất từng gán cho lớp đúng. Cây không giới hạn độ sâu để giá trị này tụt xuống 0, và vì log loss không bị chặn trên tại đó, chỉ riêng 23.1% số mẫu đủ đẩy toàn bộ chỉ số lên 8.309. Ba mô hình còn lại đều giữ một sàn dương: 0.0085 với cây độ sâu 3, 0.0032 với Random Forest và 0.0008 với XGBoost. Nói cách khác, regularization và ensemble không làm mô hình bớt tự tin mà làm nó *không bao giờ chắc chắn một cách sai lầm tuyệt đối*, và đó mới là điều log loss thưởng. XGBoost được phép tự tin hơn vì độ tự tin đó có calibration tốt, như top-label ECE 0.0117 ở Mục VI. xác nhận.



Hình 7: So sánh log loss và mức độ tự tin của cây đơn với các ensemble cây.

VIII. Thảo luận

8.1 Trả lời các câu hỏi nghiên cứu

RQ1. H1 được xác nhận: XGBoost đạt mean 5-fold log loss thấp nhất (0.382 ± 0.007) đồng thời giữ accuracy và macro-F1 cao nhất. Vì không có đánh đổi giữa ba chỉ số, kết luận không phụ thuộc vào việc chọn metric nào làm tiêu chí.

RQ2. H2 chỉ được ủng hộ một phần: sau Bonferroni, XGBoost tốt hơn bốn comparator, riêng Logistic Regression thì không. Như đã phân tích ở Mục VI., nguyên nhân nằm ở độ phân giải của thiết kế chứ không ở hiệu năng, nên protocol hiện tại không thể cho kết luận dương tính với cặp này dù chênh lệch thực có lớn đến đâu. Đây chính là ranh giới giữa hai câu hỏi thường bị gộp làm một: mô hình nào xếp hạng cao hơn, và chênh lệch có nhất quán qua fold hay không.

RQ3. H3 được xác nhận ở cả hai vế. Scaling cải thiện cả hai mô hình Track A. Với cây, vế thứ hai đúng ở dạng đã phát biểu nhưng bác bỏ một cách diễn giải thường gặp. Log loss giảm đơn điệu từ 8.309 xuống 0.474, 0.406 và 0.382, song tỷ lệ mẫu có $p_{\max} > 0.99$ không giảm theo: XGBoost tự tin hơn cả Random Forest lẫn cây độ sâu 3. Yếu tố quyết định là xác suất bằng 0 gán cho lớp đúng, vốn chỉ xuất hiện ở cây không giới hạn độ sâu. Ensemble không thắng nhờ bớt tự tin, mà nhờ không bao giờ sai một cách tuyệt đối.

RQ4. Top-label ECE của XGBoost là 0.0117 và chỉ dao động trong khoảng 0.0117-0.0144 khi số bin thay đổi từ 5 đến 20, nên kết luận “calibration tốt” không phải hệ quả của một lựa chọn binning thuận lợi. H4 được ủng hộ ở mức tổng thể nhưng không ở mức từng lớp, vì chỉ số classwise của CL bị chi phối bởi tần suất lớp chứ không bởi độ tin cậy của dự đoán.

8.2 Đối chiếu với nghiên cứu trước

Kết quả nhất quán với ba nhận định trong tài liệu, nhưng ở những mức độ khác nhau.

Thứ nhất, lợi thế của ensemble cây so với cây đơn trên dữ liệu bảng phù hợp với cơ chế mà Breiman mô tả [3] và với kết quả thực nghiệm của Chen và Guestrin [4]. Tuy nhiên, biên độ ở đây khiêm tốn: log loss chỉ giảm 0.024 từ Random Forest sang XGBoost, nhỏ hơn nhiều so với khoảng cách giữa bất kỳ ensemble nào với cây không regularization.

Thứ hai, nhận định của Guo và cộng sự rằng hiệu năng phân loại và calibration là hai khía cạnh tách biệt [6] được tái hiện theo chiều ngược với công trình gốc. Guo quan sát mạng nơ-ron hiện đại *overconfident nghiêm trọng*; XGBoost ở đây chỉ *overconfident nhẹ* và nhất quán (ECE 0.0117), nên temperature scaling nhiều khả năng mang lại cải thiện biên. Trường hợp minh họa rõ nguyên tắc đó lại là Naive Bayes: accuracy 0.589 nhưng log loss 2.211, tức xác suất sai lệch nghiêm trọng mà xếp hạng lớp không phản ánh.

Thứ ba, cảnh báo của Demšar về so sánh bội [7] tỏ ra đúng nhưng theo hướng bảo thủ hơn dự kiến. Demšar khuyến nghị Wilcoxon cho so sánh trên *nhiều dataset*; ở đây chỉ có một dataset và năm fold phụ thuộc nhau, nên năm chênh lệch không phải năm quan sát độc lập. Vì vậy các p-value trong Bảng 2 nên được đọc như chỉ báo về tính nhất quán qua fold, không phải như kiểm định về khả năng khái quát sang quần thể bệnh nhân khác.

IX. Phân tích lỗi và hạn chế

9.1 Hai chế độ lỗi

Lỗi của các mô hình tập trung vào hai chế độ khác nhau về bản chất.

Chế độ thứ nhất gắn với lớp hiếm. Lớp CL chỉ có 254 mẫu, tương đương 50 hoặc 51 mẫu mỗi validation fold, nên mọi ước lượng riêng cho lớp này đều có độ bất định cao; đó là lý do macro-F1 thấp hơn accuracy ở mọi mô hình và là lý do không nên đọc classwise ECE của CL như bằng chứng về độ tin cậy.

Chế độ thứ hai gắn với xác suất cực đoan và không bị accuracy phát hiện. Decision Tree không giới hạn độ sâu vẫn đạt accuracy 0.769, gần bằng các mô hình đứng đầu, nhưng log loss lên tới 8.309 do 23.1% quan sát nhận xác suất bằng 0 cho lớp đúng. KNN với k nhỏ mắc cùng lỗi này vì cùng nguyên nhân, còn Naive Bayes đạt log loss 2.211 do giả định độc lập Gaussian tạo likelihood quá tự tin trên các xét nghiệm có tương quan. Cả ba trường hợp cho thấy một mô hình có thể xếp đúng lớp mà vẫn ước lượng xác suất sai nghiêm trọng.

Về khả năng quy trách nhiệm cho từng lỗi, các track đã tạo confusion matrix OOF và feature importance, trong đó Bilirubin, Prothrombin Time, Copper, Albumin và tỷ lệ Bilirubin/Albumin thường xếp cao. Tuy nhiên importance chỉ đo mức độ mô hình sử dụng biến, không chứng minh quan hệ nhân quả. Nghiên cứu vì vậy không gán nguyên nhân lâm sàng cho bất kỳ dự đoán sai nào.

9.2 Hạn chế nghiên cứu

Ba giới hạn có thể làm score và p-value lạc quan hơn thực tế. Median, encoder và scaler được fit trên toàn bộ train trước cross-validation nên thống kê của phần validation đi vào tiền xử lý. Việc tuning và đánh giá dùng chung một bộ fold thay vì nested CV tạo selection bias. Protocol được chốt sau khi đã có kết quả sơ bộ, nên đây không phải nghiên cứu tiền đăng ký.

Hai giới hạn còn lại thu hẹp phạm vi kết luận. Với $n = 5$, Shapiro-Wilk có power thấp và Wilcoxon có p-value rời rạc, nên suy diễn thống kê chỉ đo tính nhất quán qua fold. Runtime được ghi trên một môi trường không lưu cấu hình phần cứng, nên chỉ mô tả lần chạy hiện tại. Toàn bộ kết luận dựa trên validation nội bộ và không chứng minh hiệu quả lâm sàng hay khả

năng khái quát sang quần thể bệnh nhân khác.

X. Tái lập kết quả

Mã nguồn được lưu tại [GitHub Hepatic-Model-Comparison](https://github.com/AIVIETNAM-AIO-DoHongNhat/Hepatic-Model-Comparison). Seed chung là 42. Môi trường authoritative được pin trong `requirements.lock.txt`; `requirements.txt` chỉ nêu lower bound nên không thay thế được bản ghi provenance.

Cài đặt môi trường

```
git clone https://github.com/AIVIETNAM-AIO-DoHongNhat/Hepatic-Model-Comparison.git
cd Hepatic-Model-Comparison
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
```

Dữ liệu cuộc thi được đặt trong `data/raw/`. Người tái lập chạy notebook theo thứ tự: 01 EDA, 02 preprocessing, 03 baseline, 04-06 ba model tracks, 07 report assets và 08 statistics. Notebook 02 tạo dữ liệu processed và fold ID; 04-06 tạo score/model/figure; 07-08 tạo bảng báo cáo, inference và calibration.

Kiểm tra artifact không ghi đè dữ liệu

```
python scripts/reproduce_all.py --project-root .
python scripts/run_final_analysis.py scores --project-root .
python scripts/run_final_analysis.py inference --project-root .
python scripts/run_final_analysis.py calibration --project-root .
```

Chế độ mặc định chỉ đọc: kiểm tra môi trường, hash đầu vào, bảng score, OOF, cổng tái tạo và calibration. Chế độ `--full` chạy lại notebook 02-06 rồi so artifact mới với bản trước, nên chỉ dùng trên clone sạch. Nếu môi trường không khớp các phiên bản đã pin, việc kiểm tra dừng lại là hành vi mong đợi.

Cấu hình siêu tham số đầy đủ của sáu mô hình xem Bảng 3 (Phụ lục B); phân công xác nhận nội dung xem Bảng 4 (Phụ lục D).

Kết quả kiểm chứng tái lập

Cơ chế trên đã được áp dụng và cho ba kết quả đáng ghi nhận, trình bày ở đây vì chúng định lượng mức độ đáng tin của các con số trong báo cáo.

Cổng tái tạo OOF đạt gần như bit-for-bit. Chạy lại toàn bộ quy trình XGBoost trong môi trường đã pin tái tạo `scores_track_c.csv` với sai lệch metric lớn nhất 5.55×10^{-17} , đạt 5/5 fold ở dung sai 10^{-5} . Trong 15 ô metric, 14 ô khớp chính xác từng bit; ô còn lại lệch đúng một đơn vị cuối của kiểu `double`. Nhờ cổng này, dự đoán out-of-fold dùng cho phân tích calibration ở Mục VI. được xác nhận là cùng một artifact đã sinh ra bảng điểm, không phải một lần chạy lại xấp xỉ.

Nguyên nhân sai lệch là môi trường, không phải mã nguồn. Trước khi môi trường được

pin, cùng mã và cùng dữ liệu chạy trên Python 3.13.3 với XGBoost 3.3.0 cho 0/5 fold đạt công, chênh lệch metric tối đa 0.0169 - lớn hơn cả chênh lệch log loss 0.024 giữa XGBoost và Random Forest. Nói cách khác, nếu không kiểm soát môi trường thì riêng phiên bản thư viện đã đủ tạo ra sai lệch cùng bậc độ lớn với hiệu ứng mà nghiên cứu muốn đo. Kết quả cũ này được giữ lại trong `results/diagnostics/` và đánh dấu đã bị thay thế.

Có một giới hạn tái lập không khắc phục được ở tầng phần mềm. Khi chạy lại toàn bộ notebook, Track A và Track B tái tạo giống hệt từng byte, nhưng log loss của Random Forest ở fold 3 lệch 1.11×10^{-16} . Nguyên nhân là `n_jobs=-1` khiến 600 cây được cộng theo thứ tự luồng do hệ điều hành quyết định, mà phép cộng dấu phẩy động không có tính kết hợp. Đây là đặc tính của phần cứng chứ không phải lỗi pipeline; mức lệch nhỏ hơn dung sai cổng khoảng 11 bậc độ lớn nên không ảnh hưởng kết luận nào. Vì vậy quy trình kiểm tra so sánh *theo giá trị* với ngưỡng 10^{-12} thay vì so từng byte.

Bài học phương pháp luận rút ra là notebook chỉ lưu tên kernel chứ không lưu phiên bản thư viện, và khoảng trống đó từng bị chẩn đoán nhầm thành mất provenance. Nguyên tắc áp dụng cho mọi artifact số về sau: chốt môi trường trước, rồi mới điều tra chênh lệch số.

XI. Kết luận và hướng phát triển

Trong phạm vi dữ liệu và protocol hiện tại, XGBoost là mô hình tốt nhất trong sáu ứng viên nhờ log loss thấp nhất, macro-F1 cao nhất và calibration OOF tốt. Giá trị chính của nghiên cứu không chỉ nằm ở mô hình thắng mà còn ở quy trình so sánh dùng chung fold, kiểm định có hiệu chỉnh và kiểm tra calibration - nhờ đó phân biệt được đâu là chênh lệch nhất quán qua fold và đâu là chênh lệch mà thiết kế hiện tại chưa đủ độ phân giải để kết luận. Kết luận này chỉ áp dụng cho đánh giá nội bộ hiện có và cần được cập nhật khi có đánh giá ngoài mẫu độc lập.

Ba hướng ưu tiên là: (1) repeated hoặc nested stratified cross-validation để tách tuning khỏi đánh giá và tăng độ ổn định; (2) đánh giá calibration theo từng lớp, thử temperature/vector scaling trên một calibration split độc lập, đồng thời theo dõi riêng lớp CL; (3) thử blending xác suất giữa XGBoost và Logistic Regression theo trọng số được chọn hoàn toàn trong validation. Các thử nghiệm mới phải chốt protocol trước khi xem kết quả và ghi đầy đủ provenance.

XII. Tài liệu tham khảo

- [1] E. R. Dickson et al., “Prognosis in primary biliary cirrhosis: Model for decision making”, *Hepatology*, vol. 10, no. 1, pp. 1-7, 1989. DOI: 10.1002/hep.1840100102
- [2] E. R. Dickson et al. “Cirrhosis patient survival prediction [dataset]”, UCI Machine Learning Repository, Accessed: Aug. 3, 2026. [Online]. Available: <https://archive.ics.uci.edu/dataset/878/cirrhosis+patient+survival+prediction+dataset-1>
- [3] L. Breiman, “Random forests”, *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001. DOI: 10.1023/A:1010933404324
- [4] T. Chen et al., “XGBoost: A scalable tree boosting system”, in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA: ACM, 2016, pp. 785-794. DOI: 10.1145/2939672.2939785
- [5] G. W. Brier, “Verification of forecasts expressed in terms of probability”, *Monthly Weather Review*, vol. 78, no. 1, pp. 1-3, 1950. Accessed: Aug. 3, 2026. [Online]. Available: https://journals.ametsoc.org/view/journals/mwre/78/1/1520-0493_1950_078_0001_vofeit_2_0_co_2.xml
- [6] C. Guo et al., “On calibration of modern neural networks”, in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, PMLR, 2017, pp. 1321-1330. Accessed: Aug. 3, 2026. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>
- [7] J. Demšar, “Statistical comparisons of classifiers over multiple data sets”, *Journal of Machine Learning Research*, vol. 7, pp. 1-30, 2006. Accessed: Aug. 3, 2026. [Online]. Available: <https://jmlr.org/papers/v7/demsar06a.html>

Phụ lục

A Thông tin bổ sung

1. **AI VIET NAM:** Thông tin chương trình tại aivietnam.edu.vn.
2. **GitHub Repository:** [Hepatic-Model-Comparison](#).
3. **Dataset:** CSV cuộc thi được đặt trong `data/raw/`; benchmark UCI liên quan được trích dẫn trong Related Work. Việc phân phối lại dữ liệu phải tuân theo quy định của ban tổ chức.
4. **Model Checkpoints:** Sáu model đã fit được lưu trong `results/models/`. Kết quả chính dựa trên CV/OOF, không dựa vào một checkpoint đơn lẻ.
5. **Experiment Logs:** Điểm từng fold và runtime nằm trong thư mục `results/`: một bảng tổng hợp, ba bảng theo track và một bảng runtime.

6. **Supplementary Results:** Hình trong figures/, bảng trong tables/, OOF và manifest trong results/oof/.
7. **Presentation:** Slide hoặc video trình bày chưa được lưu trong repo tại thời điểm khóa bản báo cáo này.

B Cấu hình thí nghiệm đầy đủ

Mọi mô hình dùng seed 42 và được fit lại từ đầu trên từng training fold. Cột “Quét” ghi không gian tìm kiếm; cột “Chốt” ghi cấu hình đã freeze trước khi hợp nhất bảng điểm. Các tham số không liệt kê giữ mặc định của thư viện.

Bảng 3: Không gian siêu tham số và cấu hình cuối của sáu mô hình.

Mô hình	Quét	Chốt
KNN	<code>n_neighbors</code> {3, 5, 7, 9, 11, 15, 21, 31, 41, 51}	$\in$ $k = 51$; uniform weights; Minkowski $p = 2$
Logistic Regression	không quét	L2, $C = 1$, lbfgs, max_iter=1000
Decision Tree	<code>max_depth</code> {2, 3, 4, 5, 6, 8, 10, 12, 15, 20, None}	$\in$ max_depth=3; Gini; min_samples_leaf=1
Naive Bayes	không quét	GaussianNB, var_smoothing= 10^{-9}
Random Forest	<code>n_estimators</code> $\in$ {200, 400, 600}; <code>max_depth</code> $\in$ {6, 8, 10, 14, None}	600 cây, max_depth=14, n_jobs=-1
XGBoost	<code>n_estimators</code> $\in$ {200, 400}; <code>max_depth</code> 2-6; <code>learning_rate</code> $\in$ {0.03, 0.05, 0.10, 0.15, 0.20}	400 cây, max_depth=2, lr=0.15, eval_metric=mlogloss

Môi trường authoritative (`requirements.lock.txt`): Python 3.9.18, scikit-learn 1.6.1, XGBoost 2.1.4, NumPy 1.26.4, pandas 2.3.3, SciPy 1.13.1, Matplotlib 3.9.2. Notebook không ghi model CPU, RAM hay GPU, nên runtime trong Mục VI. chỉ mô tả lần chạy hiện tại.

C Nguồn artifact

- Hiệu năng: `results/scores_all.csv`, `tables/report_model_comparison.csv`.
- Kiểm định: `tables/report_significance.csv`, `tables/assumption_checks.csv`.
- Calibration: `results/oof/`; trong `tables/` có `calibration_metrics.csv` và `calibration_ece_bin_sensitivity.csv`.
- Ablation: trong `tables/` có `knn_scaling_ablation.csv` và `tree_vs_ensemble.csv`.
- Provenance: `requirements.lock.txt`; trong `results/oof/` có manifest, công tái tạo và metric từng fold; bản chẩn đoán đã bị thay thế nằm trong `results/diagnostics/`.

D Phân công xác nhận nội dung

Bảng 4: Người chịu trách nhiệm xác nhận từng phần nội dung khoa học.

Thành viên	Phần xác nhận cuối
Trương Trung Tín	Dữ liệu, tiền xử lý, folds, Random Forest, XGBoost
Lê Đức Tùng Dương	KNN, Logistic Regression, ablation scaling
Đỗ Hồng Nhất	Decision Tree, Naive Bayes, cây đơn-ensemble
Đinh Văn Anh Khôi	Kiểm định, khoảng tin cậy, hiệu chỉnh, calibration
Nguyễn Thị Cẩm Vân	Hình, bảng, tích hợp báo cáo và kiểm soát chất lượng